壹、前言

一、 研究動機

珊瑚礁作為海洋生態環境的重要生存指標，但 30 年來，氣候變化導致超過半數的珊瑚礁生態系統的死亡，卻幾乎沒有做任何事情來拯救。1998 年，全球有整整 16%的熱帶珊瑚礁死亡，而到了 2016 年，情況變得更糟了：全球 70%的珊瑚礁遭到破壞，有些更是無法挽回的。這一年，澳大利亞的大堡礁有整整 30%的珊瑚礁慘遭浩劫，而更糟的是，在隔年夏天，這個數據上升到了 50%。（Ruth Gates，2016）。而指標性生物常用於測量環境品質，反推區域受到污染的情形，本研究希望透過觀察指標性生物的族群變化來進行生物監測，因此本研究將整合台灣各海域的指標性生物的數據透過機器學習去預測珊瑚礁的覆蓋率。

二、 研究目的

(一) 了解各指標性生物與珊瑚間的相關係數與重要性並找出最有影響力的特徵。
(二) 比較不同特徵篩選方式對模型準確度的影響。
(三) 比較不同的機器學習方法預測台灣珊瑚礁覆蓋率。

貳、文獻探討

一、 珊瑚礁概況

2022 年 6 月，台灣環境資訊協會公布了台灣珊瑚礁體檢 12 年的成果報告，從 2009 年到 2020 年，內容包含台灣和離島的珊瑚礁海域，一共 25 處珊瑚礁生態的長期變化。報告中，以「生態健康紅綠燈」的燈號顯示，說明各地珊瑚礁生態系的總體健康程度。其中「紅燈」代表健康岌岌可危，共有三處，為北海岸與東北角、東海岸、小琉球。「黃燈」代表健康堪憂，也有三處，為墾丁、綠島、澎湖嶼坪。「綠燈」代表健康良好，但只有蘭嶼是綠燈 (台灣資訊協會，2020)

二、 指標性生物

國際社會目前大多採用「物種指標」來表示生物多樣性變化， 而物種指標需要具備下列特徵(The Work Banks，1995)：具有足夠的敏感性來指示早期的環境變化，它具有環境變遷的預警作用、具有較廣的地理分布範圍、當環境改變時，此類生物的分布範圍也會改變，而容易被偵測出來、比較容易收集資料及量度者、能夠用來

反應只是因人類干擾而產生的變化。而台灣資訊協會（2019）對珊瑚的指標性生物評選標準與國際社會的標準相符，因此台灣資訊協會的數據具有參考價值。

三、 機器學習模型比較

表 2-1

模型	優點	缺點	文獻出處
線性回歸	1、 實作簡易 2、 計算量小、速度快、儲存空間低 3、 方便用於觀測樣本概率	1、 特徵空間大時，效果不好 2、 欠缺擬合，準確率不高。 3、 無法有效處理大量多類數據。	魏佳美 (2018)
決策樹	1、 對於雜訊資料有很好的容忍度。 2、 解釋性高，可讓使用者易於評估結果 3、 透過樹狀結構將資料進行減量，提高資料的分析與處理	1、 決策節點訓練樣本數目有可能太小以致犯錯率提高 2、 過多的節點可能隱藏規則冗餘的特性	陳俊旗 (2013)
梯度提升樹	1、 適應性佳 2、 可以處理十分複雜的非線性問題 3、 能夠有效的減小的資料中的雜訊	1、 特徵空間大時，效果不好。 2、 欠缺擬合，準確率不高。 3、 無法有效處理大量多類數據。	王禎祥（2021）
隨機森林	1、 能處理多筆特徵資料。 2、 即使在特徵遺失的狀況下，仍能夠平衡誤差。 3、 能夠同時處理分類及回歸。	1、 不易處理特徵較少的資料。 2、 處理回歸時效果不比處理分類好。	鄭揚蓁（2022）
馬可夫預測	1、 實作簡易、容易理解。 2、 能依據資料設計不同之轉移概率。	1、 由於無記憶性，易受複雜的外部因素影響。 2、 當數據稀缺時，轉移矩陣之精確度將下降。	楊明錞等人（2011）
灰色馬可夫	1、 能依據數據特性自動調整模型。 2、 能利用少量樣本進行預測。	1、 容易受到初始直影響。 2、 對於長期預測能力較弱。	楊明錞等人（2011）
註：研究者整理			

基於表 2-1 可知，由於本研究所使用珊瑚礁特徵較多的情況下不適用於馬可夫

系列的模型、資料量大，不適合於線性回歸，決定使用較為適合的決策樹、隨機森林及梯度提升樹模型。

參、研究方法

一、 研究樣本

「台灣資訊協會」自 2008 年起展開「台灣珊瑚體檢」志工行動計劃，調查台灣 7 個地區的活珊瑚覆蓋率及指標生物數量，並探討環境對珊瑚礁的影響（台灣資訊協會，2022），其中 6 個地區檢測頻率為年資料，而墾丁則因為調查較晚所以檢測頻率為半年一次。調查地區分別為潘仔澳、基翬、墾丁、母雞岩、玉女岩、東嶼西側、東嶼東側、東嶼南側，而資料共分為「底質類群」、「環境衝擊」、「指標性魚類」、「指標性底棲無脊椎動物」四類。（如表 3-1）

表 3-1 所有特徵

特徵類別	特徵
底質類群	硬珊瑚、軟珊瑚、新死珊瑚、營養鹽指標性藻類、海綿、岩石、碎石、細沙、泥沙、其他
環境衝擊	重物敲擊造成之珊瑚損害、爆裂物造成之珊瑚損害、其他原因造成之珊瑚損害、漁業垃圾、一般垃圾
指標性魚類	石鱸、笛鯛、石斑、裸胸鯙、蘇眉、蝴蝶魚、鸚哥魚、隆頭鸚哥
指標性底棲無脊椎動物	大法螺、魔鬼海膽、馬糞海膽、鉛筆海膽、棘冠海星、龍蝦、櫻花蝦、梅花參、硨磲貝

為了檢視生物與珊瑚之關係，指標性生物的食性是十分重要的，其食群可分為「食肉性」、「食藻性」、「食珊瑚性」、「食屑性」、「其他」五大類。（如表 3-2）

表 3-2 指標性生物食性表

食性	生物
食肉性	石鱸、笛鯛、石斑、老鼠魚、裸胸鯙、蘇眉、大法螺
食藻性	魔鬼海膽、馬糞海膽、鉛筆海膽
食珊瑚性	蝴蝶魚、鸚哥魚、隆頭鸚哥、棘冠海星
食屑性	龍蝦、櫻花蝦、梅花參
其他	硨磲貝
註：台灣資訊協會於 2019 年整理	

二、 特徵篩選

台灣資訊協會提供的資料中共有 36 項特徵，其中在台灣資訊協會（2019）的定義中我們的目標特徵珊瑚礁的覆蓋率即為硬珊瑚與軟珊瑚的覆蓋率加總，而其餘的特徵需要

透過其他方法篩選。本研究所採用的篩選方式為「相關係數」、「特徵重要性」，整理如表 3-3。

表 3-3 特徵篩選方法

篩選方式	相關係數	特徵重要性
內容	相關係數可用來代表兩組樣本間關係的密切程度，相關係數 $r = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \overline{y})^2}}$ Jacob Cohen（1992）對皮爾森係數的關聯程度曾做過以下劃分：$0.1 \leq \lvert r \rvert < 0.3$為低度相關；$0.3 \leq \lvert r \rvert < 0.5$為中度相關；$0.5 \leq \lvert r \rvert < 1.0$為高度相關。	基於樹的演算法模型，例如決策樹、隨機森林等，能夠使用 Scikit-Learn 的 feature_importances_計算重要性。其背後原理是透過吉尼不純度來衡量各特徵對節點分裂的影響，特徵對其的改善度越大，重要性則越高。其公式如下：基尼係數 $G(p) = \sum_{i=1}^{n} p_i(1 - p_i)$

三、 研究模型

此次研究的數據屬於練續變數，因此將採用文獻探討中的回歸模型，分別為「決策樹」、「隨機森林」、「梯度提升樹」

(一) 決策樹

決策樹分類結構為決策點（decision node)與枝葉（leaf)組成節點內為同一類別變數，枝葉為分類規則，所有訓練樣本會從根節點（root node)測試所有屬性值，向下分類產生下一階子節點，步驟重複到子節點內樣本數太少或分類最佳化，決策樹便建構完成。(許宏誠，2016)

(二) 隨機森林

隨機森林是由 Tin Kam Ho(1995)所提出 的隨機決策森林(random decision forests)而來的，作為一種元估計器，擬和數據集上各個子樣本的分類決策樹，並使用平均來提高準確性和控制過度擬和。鄭揚蓁（2022）其概念為多棵的決策樹集合而成的大型模型。

(三) 梯度提升樹

梯度提升的核心思想是通過逐步改進模型的預測能力，通過結合多個弱學習器（weak learner）來建立一個強大的預測模型。梯度提升首先初始化一個預測模型（例如回歸樹、決策樹等）並通過擬合一個弱學習器（例如回歸樹）來預測殘差。將新的弱學習器添加到模型中，並將其預測值與之前的模型預測值相加。進行多次迭代，每次迭代都在之前模型的基礎上進一步改進預測能力。（魏佳美，2018）而梯度提

升樹（Gradient Boosting Trees）是根據以上基礎而產生的。假設 x 為輸入樣本，w 為回歸樹的參數，a 為每棵樹的權重，其定義的加法模型如下：

$$F(x;w)=\sum_{i=0}^{N} a_t h_t(x;wt)$$

四、 模型評估方法

為了解模型是否真的有效，將 80%的資料用於訓練，剩下 20%的工具用於檢測。將使用 RMSE 及 R-square 作為評估預測值及實際值的方式，並透過十次交叉驗證確認模型是否有發生過度擬合的現象。各評估方法內容整理於表

方法	內容
RMSE	又稱均方根誤差，用於檢測預測值與實際值的指標，值越低模型越精準，公式如下： $$RMSE=\sqrt{\sum_{i=1}^{n}(y_{ti}-y_i)^2}$$ 其中y_{ti}為第 i 項預測值，y_i即為第 i 項準確值，RMSE 及為兩者的均方根差。
R-square	R-square 亦是用來判斷模型準確度的指標，公式如下： $$R^2=\sum_{i=1}^{n}(\hat{y_i}-\overline{y})^2+\sum_{i=1}^{n}(y_i-\hat{y_i})^2$$ 其中 R-square 值會介於 1 到 0 之間，如果值越高，則代表模型效能越好。
十次交叉驗證	常用來判斷模型是否過度擬和的指標，本次研究使用的是 k-fold cross-validation。其方法會將資料切成 k 份，不重複的選擇一份作為測試集，其他 k-1 份做為訓練集，透過輸出每次的 RMSE 或 R-square 值作為判斷模型是否過度擬和。

肆、研究分析與結果

一、 特徵篩選結果

(一) 相關係數結果

利用相關係數公式全部特徵的相關係數長條圖如圖 4-1，其中可以看到大部分的特徵對珊瑚交的覆蓋率並沒有很大的相關性，只有少部份較明顯。

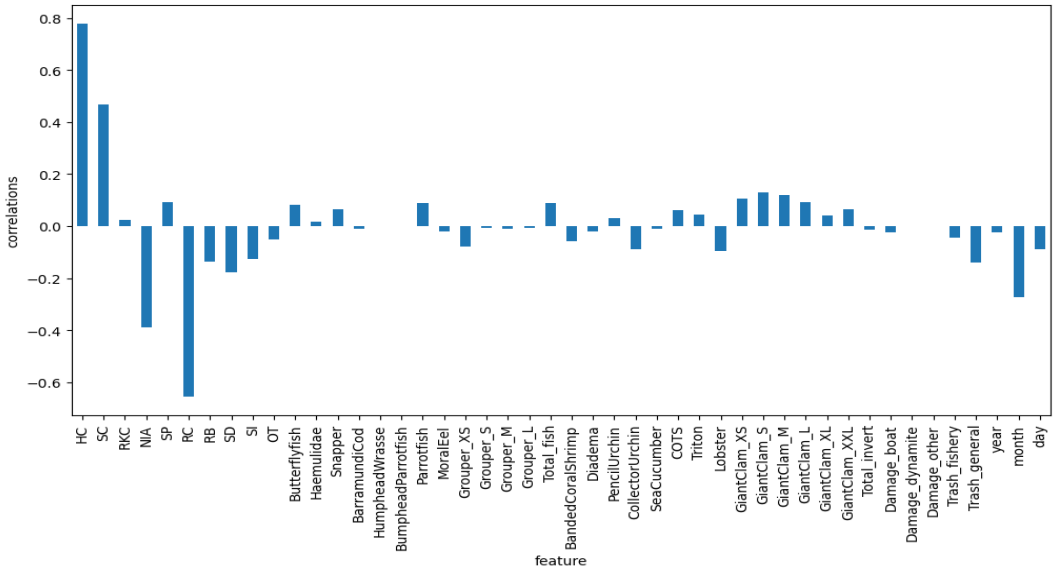

圖 4-1 各特徵與珊瑚覆蓋率的相關係數長條圖

(二) 特徵重要性

利用 Scikit-Learn 的 feature_importances_所提取決策樹及隨機森林的特徵重要性長條圖如圖 4-2，其中可以看到大部分的特徵對模型的準確率預測上並沒有很大的貢獻。而梯度提升樹特徵重要性長條圖如圖 4-3，其中亦可以看到大部分的特徵對模型的準確率預測上並沒有很大的貢獻。

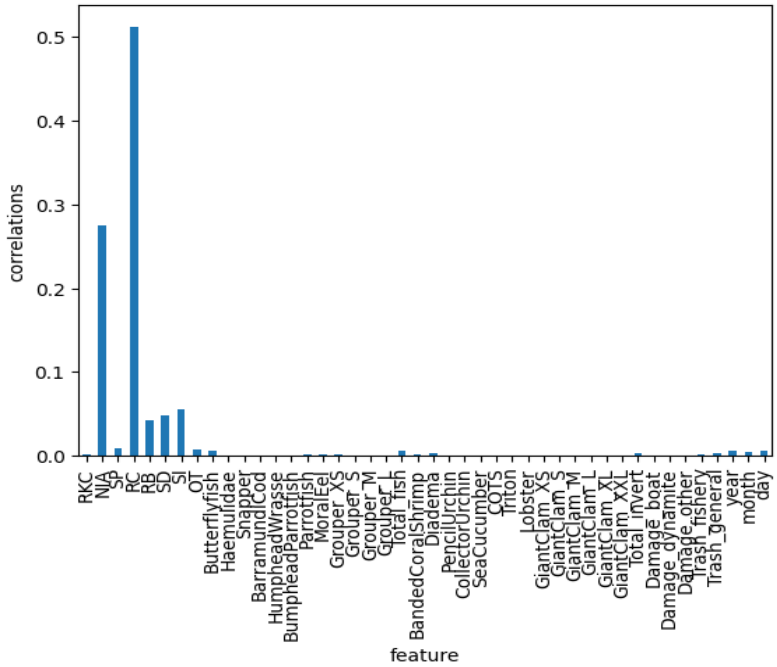

圖 4-2 由決策樹提取各特徵與珊瑚覆蓋率特徵重要性長條圖

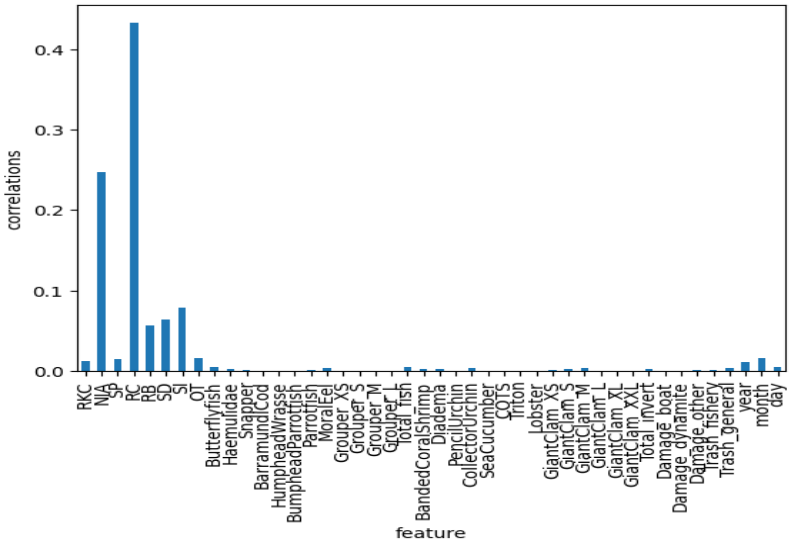

圖 4-3 由梯度提升樹提取各特徵與珊瑚覆蓋率特徵重要性長條圖

(三) 篩選特徵比較

根據皮爾森係數的分類，本研究所計算出有影響力的特徵如表，共計有 15 種特徵具有影響力，而其他不再表中的特徵即被歸類為不具影響力。特徵重要性本則依據 10 的次方進行分類，整理出特徵重要性大於10^{-3}，意旨可以於圖中明顯看到的所有特徵。將所篩選出的特徵整理於下表 4-1。

表 4-1 各方法篩選出的特徵

類別	高度相關	中度相關	低度相關
相關係數	RC	NIA	SD, Trash_general, RB, GiantClam_S, SI, GiantClam_M, GiantClam_XS
類別	大於10^{-1}	大於10^{-2}	大於10^{-3}
決策樹特徵重要性	RC, NIA	SI, SD, RB	SP, OT, Butterflyfish, Total_fish, Trash_general, Total_invert, Diadema, RKC, Trash_fishery, Parrotfish, Grouper_XS, MoralEel
梯度提升樹特徵重要性	RC, NIA	SI, SD, RB, OT, SP, RKC	Total_fish, Butterflyfish, Trash_general, MoralEel, CollectorUrchin, GiantClam_M, Diadema, Haemulidae, GiantClam_S, BandedCoralShrimp, Total_invert, GiantClam_XS, Damage_other, Parrotfish, Snapper

由表 4-1 可知：

1. 岩石覆蓋率（RC）與營養鹽指標性藻類覆蓋率（NIA）在三種方法皆顯得十分重要。
2. 細沙覆蓋率（SD）與泥沙覆蓋率（SI）皆與珊瑚礁覆蓋率呈低度性相關，特徵重要性皆大於10^{-2}。日常生活來源之垃圾（Trash_general）與珊瑚礁覆蓋率呈低度性相關，從梯度回歸樹所提取出的特徵重要性大於10^{-3}。

3. 不到 10 公分之硨磲貝隻數（GiantClam_XS）、殼長 20-30 公分之硨磲貝隻數（GiantClam_M）與殼長 10-20 公分之硨磲貝隻數（GiantClam_S）與珊瑚礁覆蓋率呈低度性相關，但只在由梯度提升樹提取出的特徵重要性大於10^{-3}，由決策樹所提取出的重要性則小於10^{-3}。

二、 各模型預測效果

本研究利用相關係數及特徵重要性所篩出的特徵進行模型訓練，並利用研究方法所提到的 RMSE 與 R-square 判斷準確度及利用十次交叉驗證判斷是否過度擬和，而在相關係數所篩出的特徵中，將訓練的特徵劃分為三個類別：「高度影響」，含高度影響的特徵、「中高度影響」，含高度影響與中度影響的特徵、「有影響」，含高度影響、中度影響與低度影響的特徵。再從利用 Scikit-Learn 的 feature_importances_所篩選的特徵中，因重要性分為：「類別 A」，所有大於10^{-1}的特徵、「類別 B」，所有大於10^{-2}的特徵、「類別 C」，所有大於10^{-3}的特徵，再因提取的模型不同，在類別後掛上模型縮寫「DTR」（決策樹）與「GB」（梯度提升數），例如：利用 Scikit-Learn 的 feature_importances_所篩選出決策樹內大於10^{-1}的特徵為「A_DTR」。將各預測模型結果的 RMSE、R-square 與十次交叉驗證後的平均 R-square 整理於下表 4-2、4-3 及 4-4

表 4-2 預測模型在不同特徵下的 RMSE 比較

預測模型	決策樹	隨機森林	梯度提升樹
高度影響	0.1494	0.1203	0.1269
中高度影響	0.1168	0.0932	0.0919
有影響	0.0969	0.0676	0.0673
A_DTR	0.1216	0.0932	0.0919
B_DTR	0.0916	0.0589	0.0465
C_DTR	0.0943	0.0519	0.0357
A_GB	0.1216	0.0932	0.0919
B_GB	0.0841	0.0490	0.0339
C_GB	0.0894	0.0525	0.0365

表 4-3 預測模型在不同特徵下的 RMSE 比較

預測模型	決策樹	隨機森林	梯度提升樹
高度影響	0.4454	0.6401	0.5996
中高度影響	0.6609	0.7840	0.7900
有影響	0.7666	0.8864	0.8876
A_DTR	0.6324	0.7840	0.7900
B_DTR	0.7911	0.9137	0.9462
C_DTR	0.7791	0.9331	0.9683
A_GB	0.6324	0.7840	0.7900

B_GB	0.8238	0.9402	0.9714
C_GB	0.8014	0.9315	0.9669

表 4-4 預測模型在不同特徵下的十次交叉驗證後的平均 R-square 比較

預測模型	決策樹	隨機森林	梯度提升樹
高度影響	-1.0839	-0.1943	-0.1346
中高度影響	0.3308	0.4881	0.4609
有影響	0.4885	0.7224	0.7717
A_DTR	0.0675	0.4881	0.4609
B_DTR	0.5890	0.7798	0.8842
C_DTR	0.5990	0.7954	0.9270
A_GB	0.0675	0.4881	0.4609
B_GB	0.6233	0.8077	0.9413
C_GB	0.5812	0.7933	0.9253

由表 4-及 4-15 可知：

1. 特徵類別「高度影響」不論在 R-square 抑或是十次交叉驗證後的平均 R-square 皆表現不佳，甚至產生負數的情形。相關係數的三個類別中，不論是 RMSE 抑或是十次交叉驗證後的平均 R-square，特徵類別「有影響」都表現最出色。
2. 在由從決策樹特徵重要性所篩出的特徵中，對決策樹及隨機森林而言，特徵類別「B_DTR」在 R-square 抑或是十次交叉驗證後的平均 R-square 表現最出色，對梯度提升樹來說則是特徵類別「C_DTR」。
3. 在由梯度提升樹特徵重要性所篩出的特徵中，對三個模型而言，特徵類別「B_GB」在 R-square 及十次交叉驗證後的平均 R-square 皆表現最出色。
4. 對三個模型而言，能夠使其達到最優秀 R-square 及十次交叉驗證後的平均 R-square 的特徵集皆為特徵類別「B_GB」。梯度提升樹為三種模型中在各特徵類別中表現最出色的，其中梯度提升樹搭配特徵類別「B_GB」達到本研究最高的 R-square：0.9714 及最高的十次交叉驗證後的平均 R-square：0.9413。

伍、研究討論與建議

一、 結論

珊瑚礁作為一個複雜的變因，進行其預測需經過多方考慮，透過分析研究結果所得出的結論如下：

(一) 由篩選特徵比較及各預測模型結果比較可知符合皮爾森相關係數有影響的特徵，作為訓練集時卻得出不良的預測結果，可推知大部分特徵與珊瑚礁之間呈現非線性關係，而各預測模型結果比較可知利用 Scikit-Learn 所提取出的特徵在重要性大於10^{-2}時，作為訓練集能使模型得到較為優秀的準確度。

(二) 由篩選特徵比較及各預測模型結果比較可知，本次研究中對珊瑚礁覆蓋率最有

影響的特徵為岩石覆蓋率（RC）、營養鹽指標性藻類覆蓋率（NIA）、泥沙覆蓋率（SI）、細沙覆蓋率（SD）、碎石覆蓋率（RB）、其他底值生物覆蓋率（OT）、海綿覆蓋率（SP）、新死珊瑚覆蓋率（RKC），大部分皆能直接影響珊瑚礁生存使其缺氧的特徵。

(三) 由各預測模型結果比較可知相較於決策樹及隨機森林，梯度提升樹模型能夠得到較優秀的準確率。

二、 未來展望

在台灣資訊協會的調查下，大部分指標性生物的數值皆不高，使得理論上能影響珊瑚礁的生物，卻對模型沒有任何助益，例如：棘冠海星（COTS）為珊瑚礁的天敵，在澳洲大堡礁對珊瑚礁影響甚大，在台灣海域卻基本上沒數據。因此後續研究將以收集全球各地的珊瑚礁覆蓋率及指標性生物作為研究方向。

陸、參考文獻

鄭楊蓁（2022）使用機器學習預測股市趨勢-台灣上市公司為例。國立雲林科技大學財務金融系：碩士論文。

魏佳美（2018）運用資料探勘預測旅遊需求。國立交通大學管理學院：碩士論文。

王禎祥（2021）應用機器學習回歸模型於成衣製造業銷售預測以 T 公司為例。國立中央大學資訊管理學系：碩士論文。

林明瑞、巫麗雯、劉惠元（2008）校園生物棲地物種指標建構之研究。台中教育大學報 22 期 p 59-82

吳易樺、黃朝熙、劉子衙（2014）時間序列模型對我國產業成長預測之優劣比較。應用經濟論叢 96 期 p 35-68。

楊明錞、黃英傑、梨煥玄（2011）運用灰色馬可夫鍊預測 7-ELENEn 的營收。明新學報 第 38 卷 第 1 期 p 147-161。

台灣資訊協會（2022）台灣珊瑚礁體檢 12 年成果報告。

海洋委員會海洋保護署（2022）珊瑚礁生態系。
https://www.oca.gov.tw/ch/home.jsp?id=176&parentpath=0,5,173

國立自然博物館（2011）什麼是刺絲胞動物？
http://digimuse.nmns.edu.tw/da/collections/az/cn/

Zoe Cormier（2019 年 4 月 11 日）Saving Coral。BBC NEWS。
https://www.bbc.com/ukchina/trad/vert-earth-47890492